

Preprocessing utilizzato: **autoscaling**, predefinito della funzione mypca (che applica pret='as').
Numero di PC scelte = **3**, in base allo Scree Plot.


OBIETTIVO

L'obiettivo principale di questa analisi è l'esplorazione e la valutazione della capacità delle **14 variabili chimiche e fisiche** di distinguere e raggruppare tre diverse categorie di vini rossi italiani: **Barolo (OLO)**, **Barbera (ERA)** e **Grignolino (GR)**, utilizzando l'analisi delle Componenti Principali (PCA).

DESCRIZIONE DEL DATASET

Il set di dati è composto da **178 campioni** di vino rosso distribuiti in tre categorie (OLO, ERA, GR). Ciascun campione è caratterizzato da **14 variabili** quantitative che misurano la composizione chimica (es. livelli di alcol, fenoli, magnesio, acido malico, ecc.). Queste variabili, misurate su scale diverse, costituiscono la base per l'analisi multivariata.

GRAFICO DEI LOADINGS



ASSI E VARIANZA

Grazie a questo grafico osserviamo come la prima componente principale riesca a spiegare il 36.19% di varianza totale, mentre la seconda il 19.20%.

Per lo studio sull'aggiunta di altre PC, rimandiamo alla sezione sullo scree plot.

IMPORTANZA DELLE VARIABILI

I vettori delle variabili che si estendono più lontano dall'origine (0,0) sono quelle che hanno un maggior impatto sulla variazione spiegata da PC1 e PC2 → indicano quindi le variabili più importanti per la distinzione tra vini.

Tra le più importanti troviamo:

- Alcohol
- Proline
- Color intensity
- Hue
- OD280/OD315
- Flavonoids

RELAZIONE CON GLI ASSI

La posizione del vettore indica come quella variabile influenza la PC:

- PC1 positiva (a dx) = le variabili in questa direzione, cioè con loading positivo sulla PC1, sono associate ai campioni che si trovano a destra dello score plot.

Esempi:

- Malic Acid
- Alkalinity of ash

→ Queste due variabili spingono i campioni a destra nello score plot.

- PC1 negativa (a sx) = Le variabili in questa direzione sono associate a campioni che si trovano a sinistra nello Score Plot.

Esempi:

- Flavonoids, Proline, Phenols, Alcohol e OD280/OD315 spingono i campioni a sinistra nello score plot.

- PC2 positiva (in alto) = Variabili che contribuiscono a spingere i campioni verso l'alto (es.: Hue)
- PC2 negativa (in basso) = Variabili che contribuiscono a spingere i campioni verso il basso (Alcohol e color intensity)


CORRELAZIONE TRA VARIABILI

Angolo stretto (< 90°): le variabili risultano **positivamente correlate**. Ad esempio, *Proline* e *Alcohol* presentano vettori molto vicini tra loro, indicando che vini con elevate concentrazioni di proline tendono ad avere anche valori maggiori di alcol

Angolo Largo (> 90°): Le variabili sono **negativamente correlate**. Ad esempio, *Malic ac* (a destra su PC1) è quasi opposto a *Phenols* (a sinistra su PC1), suggerendo che i vini con alti livelli di Malic ac tendono ad avere bassi livelli di Phenols.

non direi che malic ac e phenols sono opposti rispetto all'origine (non sono sulla stessa linea) piuttosto lo sono malic ac e hue

GRAFICO DEGLI SCORES



SEPARAZIONE DELLE CATEGORIE

Il grafico mostra una distinzione molto chiara tra le categorie di vini, indice del fatto che l'analisi PCA è riuscita a discriminare efficacemente le tre classi. Questo suggerisce una buona capacità del modello nell'evidenziare differenze strutturali tra gruppi:

- **Categoria OLO (=Barolo, blu)** → si trova prevalentemente sul lato sinistro (valori negativi di PC1) e basso (valori negativi di PC2). Questo indica che i campioni di barolo possiedono caratteristiche chimiche differenti rispetto agli altri due gruppi nelle variabili più correlate a PC1.
- **Categoria GR (=Grignolino, rosso)** → distribuiti nella zona centrale-superiore, presentando valori di PC2 più elevati rispetto agli altri gruppi. Ciò suggerisce che i campioni GR sono influenzati maggiormente dalle variabili che contribuiscono a PC2
- **Categoria ERA (Barbera, gialli)** → distinti e collocati nella parte destra del grafico, con valori positivi di PC1. La separazione netta di ERA suggerisce che questi campioni presentano un profilo chimico differenziato principalmente lungo la direzione di PC1.


Per concludere, possiamo dire che la separazione avviene principalmente lungo le due direzioni:

1. PC1: la componente 1 separa chiaramente OLO ed ERA.
2. PC2: la componente 2 separa la categoria GR (sopra) dalle altre due (OLO e ERA) che si trovano nella parte inferiore del grafico.

RELAZIONE TRA SCORE E LOADINGS

- **OLO** → PC1 negativa, PC2 negativa, questo indica che i campioni di questa classe sono ricchi di Flavanoids, Phenols, Proline, Alcohol.
- **GR** → PC1 neutra, PC2 positiva, questo indica che i campioni sono poveri di color intensity, ash, mg, alcohol e proline.
- **ERA** → PC1 positiva, PC2 negativa, questo indica che i campioni di questa classe sono ricchi di Malic Acid, Alcalinity Of Ash, bassi invece di variabili come flavonoids, phenols.

SCREE PLOT



Questo grafico è lo 'scree plot', utilizzato per scegliere il numero ottimale di componenti principali da mantenere.


Vediamo sull'asse X le PC e su Y la percentuale di varianza spiegata da ciascuna componente.

La curva mostra un calo nei primi punti, poi diventa quasi orizzontale.

Il gomito del grafico indica il punto dopo il quale aggiungere altre componenti non porta beneficio significativo.

In questo caso, il grafico indica che oltre la seconda, massimo terza, non ha senso andare, perché altre PC non porterebbero valore aggiuntivo.

T² vs Q (DIAGNOSI DEGLI OUTLIER)



Il grafico divide lo spazio in quattro quadranti basandosi sui limiti di confidenza (le linee nere) per le statistiche T^2 e Q .

Abbiamo scelto $PC=3$ in base allo Scree Plot.

- Asse X (T^2) → misura quanto ogni campione si discosta dalla media nel sottospazio delle prime k componenti principali. In questo caso, 3 componenti.
- Asse Y (Q) → Misura i residui di ciascuna osservazione rispetto al modello PCA. Indica quanto un'osservazione si discosta dalle strutture estratte dalle componenti principali selezionate.

INTERPRETAZIONE

La maggior parte dei campioni si trova in basso a sinistra (valori T^2 e Q bassi): questi dati sono ben rappresentati dal modello PCA.


I campioni lontani dall'aggregato centrale (in alto o a destra) possono essere considerati **potenziali outlier**:

- **Campioni con T^2 alto** → differiscono soprattutto nelle componenti principali selezionate.
- **Campioni con Q alto** → differiscono per caratteristiche non spiegate dalle prime 3 PC, hanno quindi una struttura diversa rispetto ai pattern principali.

La maggior parte degli outlier hanno valori di Q alti, e fanno parte della classe GR.

Questo grafico serve quindi ad individuare sia i campioni tipici ben spiegati dal modello, sia quelli anomali. Permette anche di valutare la bontà del modello PCA nell'includere dati inconsistenti o con pattern unici.

CONTRIBUTION PLOT CAMPIONE 96 (PRESENTAVA Q ALTI)



Abbiamo fatto un'analisi su un outlier che presentava Q alti, il campione 96 del grafico precedente.

Questo grafico risponde a 'Quali variabili chimiche rendono il campione 96 così anomalo?'

Il contribution plot mostra, per ogni variabile, quanto ha contribuito all'elevato valore di Q (=Residuo) del campione 96.

Le barre più alte, ed anche quelle negative, mostrano le variabili che spiegano la deviazione del campione 96 dal modello.

- **Mg** (magnesio) → Questo è il contributo dominante, con un valore eccezionalmente alto, circa 15.
- **Proanthoc** → anche questo contribuisce con un livello alto, circa 4.

Il vino del campione 96 ha livelli di **Magnesio** e **Proanthoc** che sono **molto più alti** rispetto al valore medio atteso per quel tipo di vino (Categoria ERA, giallo) all'interno dello spazio PC1-PC3.


Inoltre, per quanto riguarda contributo negativo:

- Ash
- Alcohol

Questo vino ha livelli di **Cenere** e **Alcol** che sono **più bassi** rispetto al valore atteso dal modello.

Invece, le variabili vicine allo 0 si comportano come ci si aspetterebbe e non contribuiscono all'anomalia del campione 96.

CONTRIBUTION PLOT CAMPIONE 122 (PRESENTAVA T2 ALTI)



Stesso esempio precedente, ma con il campione 122, che presentava T2 alti.

Messo per completezza, ma la logica segue l'esempio precedente.

RISULTATI

L'analisi è stata condotta sulla matrice dei dati dopo l'applicazione del Autoscaling (standardizzazione a media zero e varianza unitaria), un preprocessing necessario per garantire che tutte le variabili contribuiscano equamente alla PCA, indipendentemente dalla loro scala.

Lo Scree Plot (Grafico degli Autovalori) ha evidenziato un netto "gomito" dopo la PC3, indicando che la varianza significativa è concentrata nelle prime componenti. Per il modello diagnostico è stato scelto di mantenere 3 Componenti Principali (PC=3).

Il **Score Plot** di PC1 vs PC2 (che spiega cumulativamente il 55.4% della varianza) mostra una **separazione eccellente e completa** delle tre categorie di vino in cluster distinti, come discusso nella sezione sugli score plot.

CONCLUSIONI

L'analisi PCA ha dimostrato di essere uno strumento estremamente efficace per l'analisi esplorativa del set di dati.

1. **Distinzione Perfetta:** Le PC1 e PC2 consentono di distinguere chiaramente le tre categorie di vini rossi (Barolo, Barbera, Grignolino) in cluster ben separati. La possibilità di distinzione è quindi elevatissima e non lascia spazio a dubbi.
2. **Impronta Chimica:** Le tre categorie possiedono profili chimici ben definiti che ne guidano la separazione.
3. **Qualità Dati:** L'identificazione di alcuni *outlier* (Q alto), come il campione 96 guidato da Mg e Proanthoc, suggerisce che il set di dati contiene campioni con misurazioni estreme o che i campioni stessi sono atipici, richiedendo potenzialmente un'ulteriore indagine o l'esclusione di tali punti prima di costruire un modello predittivo definitivo