

Report Olive Oil

Obiettivo

L'obiettivo di questo lavoro è testare, in primo luogo, diverse combinazioni di distanze e linkage, attraverso analisi cluster del dataset 'olive oil'.


L'analisi comprende:

1. Samples Dendrogram.
2. Scores PC1 e PC2 calcolati attraverso una threshold di cutoff.
3. Clustering delle variabili basandosi sulla distanza di correlazione.

Inizialmente verrà applicato un processo di clustering gerarchico, che verrà poi confrontato con altri metodi, come k-means e metodi di densità.

Samples dendrogram

Il grafico presentato è un **dendrogramma** che visualizza il risultato di un'analisi di clustering gerarchico sui campioni. Il raggruppamento è stato eseguito adottando il **metodo di linkage di Ward**, un approccio che mira a minimizzare la varianza totale all'interno di ciascun cluster al momento della fusione. Come misura di dissimilarità tra i campioni è stata utilizzata la **distanza Euclidea**.



L'osservazione della struttura del dendrogramma, leggibile dall'asse orizzontale dei Campioni a


quello verticale della Distanza, rivela la **gerarchia di similarità** tra gli elementi. La presenza di rami che si uniscono a distanze molto basse e la formazione di *blocchi* netti ad altezze maggiori suggeriscono chiaramente che i campioni non sono distribuiti in modo uniforme, ma tendono a formare **cluster ben definiti** e distinti.

Per determinare il numero ottimale di cluster, è stato applicato una **threshold** sull'asse della Distanza. Seguendo la regola che privilegia l'intersezione delle maggiori distanze di fusione, è stato scelto un livello di taglio pari a **25**.

Attraverso questo livello di distanza, riusciamo ad identificare 4 grandi gruppi, distinti in: (**rosso, viola, blu e verde**).

Questo taglio a 25 fornisce la suddivisione più significativa dei dati in quattro sottoinsiemi omogenei (all'interno del cluster) e ben separati (tra i cluster).

Scores PCA



Dopo l'analisi PCA, abbiamo ricavato due componenti principali:

- **PC1**, che spiega il 49.2% della varianza
- **PC2**, che spiega il 22% della varianza.


L'analisi delle Componenti Principali è stata efficace, in quanto le prime due componenti, **PC1 e PC2, spiegano complessivamente il 71.2% della varianza totale** dei dati originali, evidenziando la maggior parte dell'informazione.

Vediamo già una buona divisione dei cluster, con una leggera sovrapposizione di alcuni campioni gialli nello spazio dei blu e dei viola. Inoltre, riusciamo a vedere un outlier del cluster arancione, a cui sono associati alti valori di PC1.

Per quanto riguarda l'analisi dei livelli di PCx nei vari cluster:

- Il **Cluster 3 (Giallo)** si posiziona prevalentemente nella regione dei **valori negativi di PC1** e intorno ai valori negativi-intermedi di PC2.
- Il **Cluster 1 (Blu)** e il **Cluster 4 (Viola)** si concentrano nell'area centrale, vicina a **PC1 ≈ 0** , con il viola che si spinge anche a valori fino a **4** di PC1. Il Cluster Viola, inoltre, si estende maggiormente verso **alti valori di PC2**, mentre il Blu è più centrato.
- Il **Cluster 2 (Arancione)** è nettamente separato e caratterizzato da **alti valori positivi di PC1** (circa da 1.5 a 3.5) e **bassi valori negativi di PC2**. Questa netta separazione conferma la sua unicità rispetto agli altri gruppi.

Clustering di variabili e campioni basandosi sulla correlazione



In questo grafico, possiamo vedere la matrice di correlazione tra campioni e variabili, a cui abbiamo aggiunto i cluster dei vari gruppi sulle rispettive righe/colonne.

Quello che vediamo è la concentrazione di tutte le variabili in ogni campione.

Per prima cosa, osservando il dendrogramma delle variabili, si notano raggruppamenti che presentano profili di concentrazione correlati:

- **Gruppo 1 (Rosso):** Palmitico e Palmitoleico

- **Gruppo 2 (Azzurro):** Linoleico ed Eicosanoico.
- **Gruppo 3 (Grigio):** Stearico e Oleico.

Quello che possiamo concludere è che questo suggerisce che le concentrazioni di Palmitico e Palmitoleico, ad esempio, tendono ad aumentare o diminuire insieme nei vari campioni.

Per quanto riguarda i vari campioni, divisi opportunamente in cluster, possiamo dire che:


- **Il cluster rosso** presenta bassi livelli di palmitico, palmitoleico e linoleico, mentre presenta valori crescenti degli altri acidi, fino ad arrivare ad alte concentrazioni di stearico e oleico.
- **Il cluster viola** è caratterizzato da valori intermedi di linoleico e linolenico, con bassi valori sugli altri acidi.
- **Il cluster azzurro** presenta alti valori di oleico e stearico, e bassissimi valori di eicosanoico e linolenico.
- **Il cluster verde**, infine, presenta valori elevati di palmitico e palmitoleico, andando a prendere poi valori sempre più decrescenti degli altri acidi, fino ad arrivare a bassi valori di oleico.

Per concludere, la matrice di correlazione conferma che il clustering dei campioni ha successo perché ogni gruppo identificato (Rosso, Viola, Azzurro, Verde) possiede un **profilo di acidi grassi significativamente diverso**.

Confronto tra vari metodi di clustering

Riguardo alla seconda parte dell'assignment, abbiamo confrontato i seguenti metodi:

1. Clustering gerarchico.
2. Clustering con il metodo '**k-means**'.
3. Clustering con dati non standardizzati.



Avendo già descritto l'analisi PCA dopo il clustering con il metodo di ward, concentriamoci sugli altri 2.

Dati non standardizzati

Per quanto riguarda i dati non standardizzati, il grafico mostra i campioni colorati in base alla loro **regione di origine**, prima di applicare qualsiasi algoritmo di clustering. Vediamo che possiamo già vedere alcuni cluster, come gli oli della south apulia o della sardegna ma, dall'altro canto, le altre regioni, come **N. Apulia (blu)**, **Calabria (arancione)**, **Umbria (rosso chiaro)** e **E. Liguria (viola)**, presentano una **forte sovrapposizione**, specialmente nell'area centrale e sinistra del grafico. Questa confusione dimostra che la sola informazione geografica (o le variabili non elaborate) non è sufficiente per separare in modo netto i campioni. **L'obiettivo di un algoritmo di clustering è risolvere questa ambiguità.**

K-means

Attraverso l'utilizzo dell'algoritmo K-Means, abbiamo cercato di suddividere i dati in quattro gruppi distinti, cercando di minimizzare la distanza intra-cluster.

Da quanto possiamo osservare, abbiamo 4 cluster ben distinti:

1. **Cluster Blu (ID 1):** È ben separato e coeso, posizionato nell'area dei valori positivi di PC1 e negativi di PC2.
2. **Cluster Arancione (ID 2):** È ampio e compatto, situato principalmente nell'area dei valori negativi di PC1 e compresi, per la maggior parte, tra livelli di PC2 tra -1 ed 1.
3. **Cluster Giallo (ID 3):** Questo cluster si trova al centro degli assi, quindi con valori neutri, globalmente compresi tra -1 ed 1, sia di PC1 che PC2. Troviamo, inoltre, una leggera sovrapposizione di alcuni campioni con il cluster viola.
4. **Cluster Viola (ID 4):** Questo cluster ha valori positivi di PC1 e, maggiormente, anche di PC2, tranne alcuni campioni che presentano valori negativi di PC2.

Clustering gerarchico

Rimandiamo alla sezione sopra discussa, in cui lo abbiamo introdotto.

Confrontando i vari metodi, sembra che K-Means riesca a suddividere meglio i 4 cluster per valori di PC1.


DBSCAN

A differenza dei metodi precedenti, DBSCAN è un metodo di clustering non supervisionato, non dobbiamo quindi specificare il numero di cluster come iperparametro.

Richiede:

- Epsilon = il raggio
- MinPts = numero minimo di punti all'interno della circonferenza di raggio epsilon.

Per quanto riguarda epsilon:




Sull'asse delle x troviamo i punti del dataset ordinati in modo non decrescente in base alla loro distanza dal k-esimo vicino più prossimo, dove $k = 10$.

Sull'asse y, troviamo la distanza del k-esimo vicino per ogni punto.

Il grafico mostra un punto in cui la pendenza della curva aumenta bruscamente, assomigliando a un "gomito". Questo punto di massima curvatura è il valore suggerito per epsilon.

Epsilon finale = 1.1.




Dal grafico vediamo il risultato dell'applicazione dell'algoritmo DBSCAN con MinPts = 10 e epsilon=1.1.

Possiamo vedere un grande cluster centrale (**rosso**), che rappresenta la zona più densamente popolata di campioni.

Vediamo anche un secondo cluster nella parte bassa del grafico (**giallo**), a valori positivi di PC1 e negativi di PC2.


I punti non classificati (**blu**), sono categorizzati come rumore da DBSCAN, non hanno densità sufficiente per far parte di un cluster

Possiamo concludere che DBSCAN non garantisce, in questo caso, una buona clusterizzazione sui dati, rispetto ai metodi visti precedentemente.



Con un MinPts = 20 tende a raggruppare meglio i campioni in cluster differenti, ma non ancora sufficientemente bene per competere con i metodi precedenti.

OPTICS



Sull'asse x del reachability plot troviamo l'ordine in cui i campioni sono stati analizzati dal reachability plot, basandosi sulla loro vicinanza e densità.

Sull'asse y, invece, troviamo la '**reachability distance**' di ciascun punto. È una misura della distanza minima necessaria per raggiungere un punto da un punto denso ad esso adiacente.

Troviamo diverse valli nel grafico, che rappresentano potenziali cluster.

Troviamo infatti la zona rossa (umbra) a 5-50, poi una grande zona celeste (S.Apulia) a 150-300, verde (In.Sardinia) a 320-380 e Verde (Co.Sardinia) a 380-400.

Potremmo inserire anche arancione (W.Liguria) a 480-530, anche se la valle è minima e le

altezze salgono velocemente.

Gli innalzamenti improvvisi, come 300, oppure 550, indicano che il punto nella sequenza è molto più distante del suo predecessore denso; questi picchi indicano quindi le separazioni tra i cluster o identificazione di punti di rumore, se sono estremamente elevati.

Conclusioni

L'analisi PCA è stata altamente efficace, catturando il 71.2% della varianza nei primi due componenti.

Il Clustering Gerarchico (Ward/Euclidea) ha identificato 4 gruppi che presentano profili di acidi grassi significativamente diversi (confermato dalla heatmap).

Nel confronto, l'algoritmo k-means ha prodotto una separazione dei cluster leggermente più netta lungo l'asse PC1 rispetto al metodo gerarchico.

I metodi basati sulla densità (DBSCAN con i parametri scelti) hanno avuto difficoltà a separare i 4 gruppi, tendendo a raggruppare la maggior parte dei campioni in un unico grande cluster, indicando una densità di dati relativamente omogenea nella parte centrale del dataset.