


Analisi Dataset QSAR e Predizione con *PLS-DA* su un Set Esterno

Classificazione della Biodegradabilità molecolare
tramite Analisi Multivariata e Modellazione PLS-DA

Samuele Carpi (215241)

Alessandro Chiarabini (217425)



Descrizione del problema

Contesto

La **biodegradabilità** misura la capacità di un microrganismo di decomporre una molecola organica. È una proprietà critica per valutare l'impatto ambientale di una sostanza chimica.

Obiettivo

Costruire un modello di classificazione **PLS-DA** che predica automaticamente la biodegradabilità di una molecola a partire dalla sua **struttura chimica**, senza esperimenti di laboratorio.

Classificazione binaria


Classe 1 → Non Biodegradabile

Classe 2 → Biodegradabile

PARTIZIONE DEL DATASET



SBILANCIAMENTO DELLE CLASSI (TRAINING)



Descrizione del problema

I **23 descrittori** sono indici numerici calcolati automaticamente dalla **struttura** della molecola.

Topologici

Misurano la complessità e la connettività della molecola: quanto è ramificata, quanti legami ha, quanto è "intricata" la sua struttura.

SpMax_L, SM6_L, SpMax_A, HyWi_B(m)

Pesi Atomici Medi

Descrivono la distribuzione della massa all'interno della molecola e come questa è distribuita tra i vari atomi.

Me, Mi

Conteggio di Atomi

Contano quanti atomi di un certo tipo sono presenti: ossigeno, azoto, alogeni (cloro, bromo).

nO, nN-N, nCRX3, nCIR

Frequenze di Legame e Proprietà Elettroniche

Rilevano la presenza di legami specifici tra atomi e le proprietà elettroniche locali della molecola.

B01[C-Br], B03[C-Cl], N-073, SdO, F03[C-O], F04[C-N]

In letteratura...



Favoriscono la Biodegradabilità

- **Ossigeno e legami C-O, C-N:** rendono la molecola "aggredibile" dagli enzimi batterici.
- **Strutture semplici:** più facili da smontare per i microrganismi.
- **Bassa percentuale di carbonio puro:** meno idrofobicità, più solubilità in acqua.



Ostacolano la Biodegradabilità

- **Alogeni (Cl, Br):** legami molto stabili, difficili da rompere per i microrganismi.
- **Strutture grandi e ramificate:** i batteri faticano ad "aggredire" molecole complesse.
- **Alta percentuale di carbonio:** molecole idrofobiche, poco solubili in acqua e quindi poco accessibili.

PCA Esplorativa

PCA Esplorativa - Numero di componenti principali

Preprocessing

Il preprocessing adottato è stato l'**autoscale**.

Criterio adottato


In una PCA esplorativa, per la scelta del numero di componenti principali da utilizzare, il riferimento corretto è lo **Scree Plot**. Si sceglie il numero di PC in corrispondenza del **gomito della curva**, dopo il quale la varianza per componente si assesta su valori simili, indice che le componenti successive descrivono **rumore** e non **struttura sistematica**.

Osservazione

La curva presenta un cambio di pendenza visibile dopo la **4^a componente**, dove la varianza per PC scende sotto il **6.5%** e si assesta su valori via via più simili tra loro.

Conclusione

Sono stati scelti **4 componenti principali**.



PCA Esplorativa - Score Plot PC1 vs PC2

Separazione delle classi


Le due classi si **sovrappongono** considerevolmente su PC1 e PC2, che spiegano insieme il 39.5% della varianza.

Tendenze osservabili

Le **biodegradabili** (blu) si concentrano nella **zona centrale**, mentre le **non biodegradabili** (rosse) sono più disperse e dominano la **zona destra e in basso**. A sinistra compaiono pochi punti isolati, probabilmente outlier strutturalmente diversi dal resto del dataset.

Osservazione

Le due classi **non sono separabili** su questi due assi: la struttura del dataset è complessa e distribuita nello spazio. Per comprendere cosa guida questa distribuzione e quali descrittori separano le classi sarà necessario osservare il **biplot**, che aggiunge ai punti le frecce dei loadings.



PCA Esplorativa - Biplot

PC1 - Dimensione e complessità molecolare

- **Valori positivi (SM6_L, HyWi_B(m), SpMax_L, SpMax_A):** rappresentano tutti indici di quanto una molecola è grande e ramificata. Molecole con score PC1 positivo sono quindi molecole strutturalmente complesse.
- **Valori negativi (Mi e LOC):** descrivono caratteristiche opposte.

Le non biodegradabili tendono verso PC1 positivo, ma la separazione su questo asse non è netta.


PC2 - Contenuto di ossigeno vs. presenza di alogeni

- **Valori positivi (nO, SdO, F03[C-O]):** contatori di atomi di ossigeno o legami che coinvolgono l'ossigeno. Molecole in alto su PC2 contengono quindi più ossigeno.
- **Valori negativi (C%, B01[C-Br], B04[C-Br], nCIR):** indici di contenuto di carbonio e presenza di bromo.

Questo asse separa quindi molecole con molto ossigeno da molecole con alogeni come cloro e bromo.

Conclusione

Le **molecole non biodegradabili** si concentrano nella zona in basso a destra del biplot, corrispondente a valori positivi di PC1 (**molecole grandi e complesse**) e negativi di PC2 (**presenza di alogeni**). Questo suggerisce che dimensione molecolare elevata e alogenazione siano i fattori strutturali più associati alla non biodegradabilità. Al contrario, le **molecole biodegradabili** tendono verso PC2 positivo, dove dominano i descrittori di ossigeno



PCA Esplorativa - T^2 vs Q

Asse T^2


Misura la distanza dal **centro del modello**: valori elevati indicano campioni **estremi** ma **coerenti con la struttura del dataset** (leverage alto).

Asse Q


Misura la **varianza non spiegata** dal modello: valori oltre la **soglia** indicano campioni la cui struttura **non è catturata dalle 4 PC**.

Analisi

La maggior parte dei campioni ricade nella **zona normale (basso-sinistra)**. Si identificano **42 campioni con Q elevato** e **23 oltre entrambe le soglie**, riconducibili a molecole strutturalmente anomale rispetto al dataset. I campioni **692** e **325** - i più critici per **Q residuo** - sono stati analizzati tramite **contribution plot**.




PCA Esplorativa - Studio di un Outlier



Osservazione

Abbiamo analizzato, mediante il **Contribution Plot**, uno degli **outlier più estremi** del dataset: il campione 692. Il modello PCA **non riesce a rappresentarne correttamente la struttura** a causa del descrittore **N-073**, che è responsabile di **quasi tutto l'errore di ricostruzione**. Questo indica che il campione **692** presenta una **topologia molecolare unica** nel dataset e le sue previsioni andranno interpretate con **cautela**.



Applicability Domain

Applicability Domain

Applicability Domain

Definisce lo spazio chimico entro cui le predizioni del modello sono **affidabili**. Se una nuova molecola è troppo "diversa" dal training set, la predizione non è garantita essere attendibile.

- **Asse x (Leverage)**: distanza della molecola dal centro del training set. Oltre $h^* (=3 \cdot A)/n$ il campione è strutturalmente anomalo.
- **Asse y (Q Residuals)**: varianza della molecola non catturata dal modello. Oltre Q^* il campione non è ben rappresentato.


Test set

213/218 campioni nel dominio, solo **5 fuori (2.3%)**. Il test set è strutturalmente molto simile al training.

Xeval

635/670 nel dominio, **35 fuori (5.2%)**, risultato ottimo per un dataset esterno indipendente.

I 2 punti rossi isolati in alto a destra ($Q > 2000$) sono outlier estremi di Xeval: le predizioni su questi campioni sono **altamente inaffidabili**.



Applicability Domain


Il grafico mostra i valori di Leverage e Q Residuals per ogni campione di Xeval, evidenziando i campioni fuori dall'Applicability Domain (in rosso).

Il **97.7%** del test set e il **94.8%** di Xeval ricade nel dominio del modello, confermando che le predizioni sono strutturalmente **affidabili** per la grande maggioranza dei campioni.

I **campioni 89 e 131** emergono come outlier estremi:


- **Leverage > 0.7**
- **Q Residuals > 2000**

Questi campioni sono strutturalmente lontani dal training set le loro predizioni sono da considerare **altamente inaffidabili**.



PLS-DA

Analisi PLS-DA - Ottimizzazione della Complessità




Metodologia di Validazione

È stata applicata una **10-fold Stratified Cross-Validation** per garantire che ogni fold rispetti le proporzioni reali delle classi nel dataset, aspetto critico dato lo **sbilanciamento tra le due classi** (ogni fold contiene esattamente il 66% di classe 1 e il 34% di classe 2).

Osservazione sul classification error per classe

Il grafico a destra evidenzia che l'errore sulla Classe 2 (biodegradabili) è **sistematicamente più alto** rispetto alla Classe 1.



Identificazione dell'ottimo

Entrambi i grafici mostrano che il modello **migliora** fino a **7 LV**, dopodiché la curva si appiattisce. A 7 LV si raggiungono contemporaneamente il **minimo** del **RMSECV**, il minimo dell'**errore di classificazione medio** e la massima **Balanced Accuracy**: è quindi il punto di equilibrio ottimale. Un numero inferiore causerebbe **underfitting**, mentre l'aggiunta di ulteriori componenti porterebbe all'**overfitting**.

Analisi PLS-DA - Score Plot LV1 vs LV2

Separazione parziale lungo LV1


La prima componente latente mostra una tendenza alla separazione, con i campioni **biodegradabili** (blu) che si concentrano maggiormente nella regione negativa di LV1 (sinistra), mentre i **non biodegradabili** (rossi) tendono verso i valori più positivi (destra).

Contributo di LV2

La seconda componente latente contribuisce **meno** alla discriminazione rispetto a LV1, come evidenziato dalla distribuzione più **compatta** lungo l'asse Y.

Sovrapposizione

Nella **regione centrale** del grafico, tra -1 e 1 su LV1, osserviamo una **sovrapposizione** tra le due classi, nonostante sia meno accentuata rispetto a quella vista in precedenza su PCA. .



Analisi PLS-DA - Coefficienti di Regressione

Questo grafico fornisce un'interpretazione riguardo l'importanza dei descrittori, indicando **non solo la rilevanza, ma anche la direzione** del contributo alla classificazione: coefficienti **positivi (blu)** favoriscono la classe Biodegradabile, coefficienti **negativi (rossi)** favoriscono la classe Non Biodegradabile.

Descrittori positivi

Tra i descrittori con contributo **positivo** alla biodegradabilità, emergono:

1. **nO** ($\beta \approx +0.115$)
2. **C%** ($\beta \approx +0.100$)
3. **LOC** ($\beta \approx +0.100$)


La presenza di ossigeno nei descrittori dominanti positivi è chimicamente coerente: **molecole ricche di ossigeno** sono generalmente più biodegradabili.

Descrittori negativi

Sul versante opposto, i descrittori con contributo **negativo**, associati alla non biodegradabilità, includono:

1. **SpPosA_B(p)** ($\beta \approx -0.130$)
2. **HyWi_B(m)** ($\beta \approx -0.125$)
3. **F03[C-O]** ($\beta \approx -0.090$)

Questi descrittori sono indici di dimensione e complessità topologica: **molecole grandi e ramificate** sono strutturalmente più difficili da aggredire dai processi biologici di degradazione.



PLS-DA

True Discriminant

Analisi PLS-DA - Y Predicted Plot

Questo grafico mostra i **valori predetti $\hat{y}$** (dummy) dal modello PLS-DA per ogni campione, sia nel **training set** che nel test set.

Criteri di classificazione


Il criterio di classificazione utilizzato è il **True Discriminant** dove ogni campione viene assegnato alla classe con valore predetto $\hat{y}$ più alto. La classificazione è corretta quando, per un campione rosso, la linea rossa $\hat{y}_1$ assume un valore più alto della linea blu $\hat{y}_2$ e viceversa per i campioni blu.

Risultati

- Training set (**837** campioni): comportamento oscillante con sovrapposizioni frequenti
- Test set (**218** campioni): pattern coerente col training → **assenza di overfitting**
- Misclassificati totali: 151/1055 (14.3%)

Interpretazione

Il modello classifica correttamente **904 campioni su 1055**, con performance analoghe su training e test set, indicando una buona prestazione generale del modello ed una **buona capacità di generalizzazione**.



PLS-DA


Hybrid

PLS-DA Hybrid - Scelta del threshold



La **curva ROC** mostra il compromesso tra Sensitivity (capacità di identificare i biodegradabili) e Specificity (capacità di identificare i non biodegradabili) al variare della soglia di classificazione. L'**AUC** misura l'area sotto questa curva: vale 0.5 per un modello casuale e 1.0 per un modello perfetto.

Il modello ottiene **AUC > 0.9** sia in **CV** che sul **Test Set**, a conferma dell'assenza di overfitting e di un'ottima capacità discriminante tra le due classi.

La soglia ottimale è **0.451** anziché 0.5: il criterio di Youden massimizza la somma (Sensitivity + Specificity - 1). Abbassare leggermente la soglia compensa il fatto che il modello tende a **sottostimare** la probabilità della classe Biodegradabile, riflesso dello sbilanciamento del dataset.



PLS-DA Hybrid - Y_Predicted Plot



Rispetto al criterio **True Discriminant** analizzato in precedenza, il metodo **Ibrido** usa una singola soglia ottimale (0.451) invece di confrontare le due colonne dummy. I grafici mostrano i valori predetti per ciascun campione del dataset di Training (a sx) e Test (a dx): le “X” sul grafico, corrispondono ai campioni **misclassificati** dal modello.

Errore di classificazione

Training set: 13.7%

Test set: 15.6%

PLS-DA - Il confronto

Il metodo ibrido migliora leggermente sul training rispetto al True Discriminant, ma peggiora sul test set.

Il True Discriminant è la scelta più robusta.

<i>Misclassificazione (%)</i>	True Discriminant	Ibrido
Training Set	15.2%	13.7%
Test Set	14.7%	15.6%

Performance True Discriminant

Analisi PLS-DA - Performance del Modello

Prestazioni generali

Il modello raggiunge una **Balanced Accuracy** di **~0.82** su tutti e tre i set (Cal, CV, Test Set), indicando una **buona capacità predittiva**.

Assenza di overfitting

Il **valore di overfitting** sulla Balanced Accuracy è **0.0045**, praticamente nullo. Le performance si mantengono **stabili** dal training al test set, confermando che il modello **generalizza bene su dati nuovi**.

Asimmetria tra le classi




La **Sensitivity sulla Classe 1** (non biodegradabili) è **alta** (~0.91), stabile su tutti e tre i set. Quella sulla **Classe 2** (biodegradabili) è **più contenuta**: ~0.74 in calibrazione e CV, scendendo a 0.72 sul Test Set. Il modello è quindi **più stabile nell'identificare le molecole non biodegradabili**, comportamento atteso dato lo sbilanciamento del dataset.

Conclusione

Il modello PLS-DA con 7 LV è **robusto, ben calibrato e generalizza correttamente**. Il punto di miglioramento principale rimane la Sensitivity sulla Classe 2, in particolare sul set di predizione.

METRICA	COMPLETO
// - Calibrazione -	
Accuracy (Cal)	0.8530
Bal. Accuracy (Cal)	0.8254
Sens. CL.1 (Cal)	0.9114
Sens. CL.2 (Cal)	0.7394
RMSEC (media)	0.3600
R² Cal	0.4220
// - Cross-Validation -	
Accuracy (CV)	0.8483
Bal. Accuracy (CV)	0.8209
Sens. CL.1 (CV)	0.9060
Sens. CL.2 (CV)	0.7359
RMSECV (media)	0.3670
R² CV	0.3991
// - Predizione (Test Set) -	
Accuracy (Pred)	0.8532
Bal. Accuracy (Pred)	0.8200
Sens. CL.1 (Pred)	0.9178
Sens. CL.2 (Pred)	0.7222
RMSEP (media)	0.3625
R² Pred	0.4059
// - Indicatori Generali -	
Overfitting (Cal-CV)	0.0045
AUC CV	0.9052

Analisi PLS-DA - Confusion matrix




Selezione delle variabili

Selezione delle variabili - VIP Scores

L'analisi dei **VIP (Variable Importance Projection)** identifica 11 descrittori con **VIP maggiori a 1.0**, i quali sono considerati come contributori significativi alla discriminazione tra le due classi.

Analisi della **Top 5**:

1. **SpPosA_B(p) (VIP = 1.466)**: misura come la carica elettrica è distribuita nella molecola.
2. **SpMax_L (VIP = 1.391)**: indice che cresce al crescere della dimensione e della complessità della molecola.
3. **SpMax_A (VIP = 1.378)**: simile al precedente, misura la connettività interna della molecola.
4. **C% (VIP = 1.316)**: percentuale di atomi di carbonio nella molecola. Più carbonio c'è rispetto agli altri elementi, più la molecola tende ad essere idrofobica.
5. **HyWi_B(m) (VIP = 1.306)**: misura quanto una molecola è ramificata. Una molecola molto ramificata, come un albero con tanti rami, è più difficile da "smontare" per i microrganismi rispetto a una struttura lineare semplice.




Selezione delle variabili - Selectivity Ratio

Il **Selectivity Ratio (SR)** misura quanto il segnale discriminante di un descrittore domina sul rumore. Valori **SR > 1** indicano variabili con contributo reale alla classificazione.


Elemento chiave

HyWi_B(m) domina nettamente con $SR = 15.75$, circa il doppio del secondo descrittore (SM6_L, $SR = 7.53$). È il descrittore con il segnale discriminante più puro e specifico dell'intero set.



Selezione delle variabili - VIP Based Model (11 variabili)


Confusion Matrix - Cross-Validation Training



- Balanced Accuracy = 79.27%
- Sensitivity NonBiodeg = 89.87%
- Sensitivity Biodeg = 68.66%
- RMSECV (media) = 38.1%

True Positive (TP)
Errori (FP/FN)
True Negative (TN)


Confusion Matrix - Test Set



- Balanced Accuracy = 77.83%
- Sensitivity NonBiodeg = 91.78%
- Sensitivity Biodeg = 63.89%
- RMSEP (media) = 37.39%

Selezione delle variabili - SR Based Model (18 variabili)


Confusion Matrix - Cross-Validation Training



- Balanced Accuracy = 79.38%
- Sensitivity NonBiodeg = 91.50%
- Sensitivity Biodeg = 67.25%
- RMSECV (media) = 37.73%

■ True Positive (TP)
■ Errori (FP/FN)
■ True Negative (TN)


Confusion Matrix - Test Set




- Balanced Accuracy = 77.13%
- Sensitivity NonBiodeg = 93.15%
- Sensitivity Biodeg = 61.11%
- RMSEP (media) = 36.36%

Selezione delle variabili - Il confronto delle metriche

Confronto Strategie di Selezione Variabili - Cross-Validation Training



Confronto Strategie di Selezione Variabili - Test Set



Il modello Completo (23 variabili) supera i modelli ridotti su Accuracy, Balanced Accuracy e Sensitivity - con un vantaggio netto su quest'ultima, sia in Cross-Validation che sul Test Set. Il modello ridotto SR>1 mostra una Specificity leggermente superiore, ma il guadagno non è sufficiente a compensare le perdite sulle altre metriche.

Il modello Completo è la scelta ottimale.

Selezione delle variabili - Il confronto delle metriche

Il valore di RMSECV a 7 LV è pari a:


- **Modello completo: ≈ 0.367**
- **SR > 1: ≈ 0.377**
- **VIP > 1: ≈ 0.381**

La riduzione delle variabili introduce un errore di predizione **sistematicamente più alto**.

Conclusione

Tutti e tre i modelli si stabilizzano dopo 7 LV, confermando che la scelta del numero di componenti è robusta indipendentemente dal sottoinsieme di variabili utilizzato. Il modello completo domina su tutti i fronti: classificazione, balanced accuracy e RMSECV.

Non c'è alcun vantaggio nel ridurre le variabili.



Conclusioni



Modello finale adottato

Il modello **PLS-DA completo** a **23 variabili** e **7 componenti latenti**, con criterio ***True Discriminant***, rappresenta la **scelta ottimale**: supera i modelli ridotti ($VIP > 1$, $SR > 1$) su praticamente tutte le **metriche principali** e non introduce alcun vantaggio complessivo nel ridurre le variabili, se non una lieve **Specificity** superiore che non compensa le perdite sulle altre metriche. PLSDA **robusto** al rumore.



Performance Complessiva

Il modello raggiunge una Balanced Accuracy di **0.82** e $AUC > 0.90$, stabile tra calibrazione, cross-validation e Test Set. Il valore di overfitting è praticamente nullo (**0.0045**), confermando una solida capacità di generalizzazione. Il **94.8%** di Xeval ricade nell'Applicability Domain, garantendo predizioni affidabili sulla grande maggioranza dei campioni esterni.




Interpretazione chimica

L'analisi dei coefficienti di regressione e dei VIP scores rivela un quadro chimicamente coerente con la letteratura.

Polarizzabilità ($SpPosA_B(p)$), dimensione molecolare ($SpMax$, $HyWi_B(m)$) e contenuto di carbonio ($C\%$) sono i predittori dominanti della **non biodegradabilità**.

L'**idrofobicità** (alta percentuale di carbonio e struttura ramificata) è il principale ostacolo alla degradazione microbica. Al contrario, la presenza di ossigeno (nO , SdO , $F03[C-O]$) favorisce la **biodegradabilità** rendendo la molecola aggredibile dagli enzimi batterici.

Conclusioni - Previsioni sul Dataset Esterno Xeval




Alta copertura del dominio

Il 94.8% dei campioni ricade nell'Applicability Domain: le predizioni sono strutturalmente affidabili per 635/670 composti. Solo 35 campioni sono fuori dal dominio e sono tutti classificati come Non Biodegradabili: strutturalmente lontani dal training set, le loro previsioni sono da considerare inaffidabili.

Predominanza della Classe 1

Il 73.7% è classificato Non Biodegradabile, in linea con lo sbilanciamento del training (66%). Tutti i 176 Biodegradabili risultano nel dominio con alta affidabilità.




Appendice

Appendice

Le slide seguenti analizzano le prestazioni del metodo di classificazione **Hybrid** applicato ai **modelli ridotti** ($VIP > 1$ e $SR > 1$), mettendoli a confronto con il modello completo a 23 variabili. Si riportano infine le predizioni ottenute con questo criterio sul dataset esterno Xeval.

Appendice - Modello Ridotto VIP > 1




Cross-Validation

- Balanced Accuracy = 82.66%
- Sensitivity Classe1 = 80.11%
- Sensitivity Classe2 = 85.21%
- RMSECV (media) = 38.1%


Test Set

- Balanced Accuracy = 83.43%
- Sensitivity Classe1 = 86.30%
- Sensitivity Classe2 = 80.56%
- RMSEP (media) = 37.39%



L'AUC del modello ridotto (0.887) è leggermente inferiore rispetto al modello completo (0.905), a indicare una lieve **perdita di capacità discriminante** complessiva dovuta alla riduzione delle variabili. La soglia ottimale di Youden è **0.409**, inferiore rispetto allo 0.451 del modello completo: con meno variabili il modello tende a comprimere i valori predetti verso il centro, spostando il punto di equilibrio ottimale.

Appendice - Modello Ridotto SR > 1




Cross-Validation

- Balanced Accuracy = 83.18%
- Sensitivity Classe1 = 79.75%
- Sensitivity Classe2 = 86.62%
- RMSEP (media) = 37.73%

Test Set

- Balanced Accuracy = 82.74%
- Sensitivity Classe1 = 84.93%
- Sensitivity Classe2 = 80.56%
- RMSEP (media) = 36.36%




L'AUC del modello SR > 1 (**0.891**) è leggermente inferiore al modello completo (**0.905**), a indicare una lieve perdita di capacità discriminante dovuta alla riduzione delle variabili. Rimane comunque comparabile al modello VIP > 1 (**0.887**), nonostante utilizzi più variabili (18 vs 11), suggerendo che le variabili aggiuntive apportano un **contributo discriminante marginale**.


La soglia ottimale di Youden (**0.393**) è la più bassa tra i tre modelli (completo:**0.451**, VIP > 1:**0.409**): con questo subset il modello tende maggiormente a sottostimare la probabilità Biodeg, richiedendo una **soglia più bassa** per bilanciare ottimalmente Sensitivity e Specificity.

Appendice - Il confronto delle metriche

Confronto Strategie di Selezione Variabili - Cross-Validation Training




Confronto Strategie di Selezione Variabili - Test Set



Sul test set, i modelli ridotti superano il modello completo su **Balanced Accuracy (VIP: 0.834, SR: 0.827 vs Completo: 0.820)** e soprattutto sulla **Sensitivity (VIP e SR: 0.806 vs Completo: 0.750)**. Il modello completo rimane comunque superiore su praticamente tutte le metriche in cross-validation.

Nel True Discriminant il modello completo era la scelta netta. Con il metodo ibrido i modelli ridotti diventano competitivi in particolare sulla **Sensitivity sul Test Set, dove guadagnano oltre 5 punti percentuali**.

Appendice - Y Predicted Plot



Questo grafico mostra i valori predetti per ciascun campione del **dataset esterno Xeval**: i 199 campioni sopra la soglia vengono classificati come Biodegradabili, i 471 sotto come Non Biodegradabili. La separazione visiva tra i due gruppi è netta, con pochi campioni a ridosso della threshold, a conferma della **capacità discriminante** del modello anche sul set esterno indipendente.

FINE